STAGE

SEMAINE 1

1- Installer Python 3.x, Jupyter et VS Code. Créer un environnement virtuel (venv) avec pandas, numpy, scikit-learn, matplotlib, seaborn. Initialiser un dépôt Git.

→ Installation de l'interpréteur Python (v3.14)

Nous avons installé la version la plus récente de **Python 3**. C'est le moteur qui permet d'exécuter le code.

→ Création d'un Environnement Virtuel (venv)

Plutôt que d'installer les bibliothèques sur tout l'ordinateur, nous avons créé un dossier isolé appelé venv.

- **Pourquoi ?** Cela permet d'éviter les conflits de versions entre différents projets. Si un autre projet a besoin d'une vieille version d'une bibliothèque, il n'écrasera pas celle de ton projet actuel.
- **Isolation :** Le projet est ainsi "autonome".

→ Gestionnaire de paquets et Bibliothèques Data Science

Grâce à l'outil pip nous avons installé la pile technologique standard pour l'analyse de données :

- **Pandas & NumPy :** Pour la manipulation de tableaux de données et les calculs mathématiques.
- **Matplotlib & Seaborn :** Pour la visualisation de données (graphiques, courbes, cartes de chaleur).
- **Scikit-learn :** Pour l'implémentation d'algorithmes de Machine Learning.
- **Jupyter (ipykernel) :** Pour permettre l'utilisation de Notebooks interactifs (fichiers .ipynb) directement dans VS Code.

→ Initialisation du Contrôle de Version (Git)

git init.

Configuration d' un fichier .gitignore et **premier commit** (root-commit), ce qui a créé un historique de sauvegarde.

Synchronisation GitHub : Création d'un dépôt distant sur GitHub (zinebzd/Stage) et liaison avec le dépôt local via la branche main.

→ IDE : Visual Studio Code

Enfin, nous avons configuré **VS Code** comme interface de développement. Nous avons lié l'éditeur au "Kernel" (le noyau) de notre environnement virtuel pour que l'autocomplétion et l'exécution du code utilisent bien les bibliothèques installées précédemment.

A RETENIR : Synchroniser avec Github

1. ***git add test.ipynb***
2. ***git commit -m "Mise a jour "***
3. ***git push***

Lire 5 à 8 articles/tutoriels sur la détection d'anomalies appliquée aux logs de sécurité. Mots-clés : anomaly detection, log analysis, SIEM, unsupervised ML. Livrable : fiche de synthèse (1 à 2 pages).

Sources :

Preprints.org

ML-Driven Log Analysis for Real-Time Cyber Threat Detection in…

The escalating sophistication of cyb…

preprints.org

ManageEngine

Log360

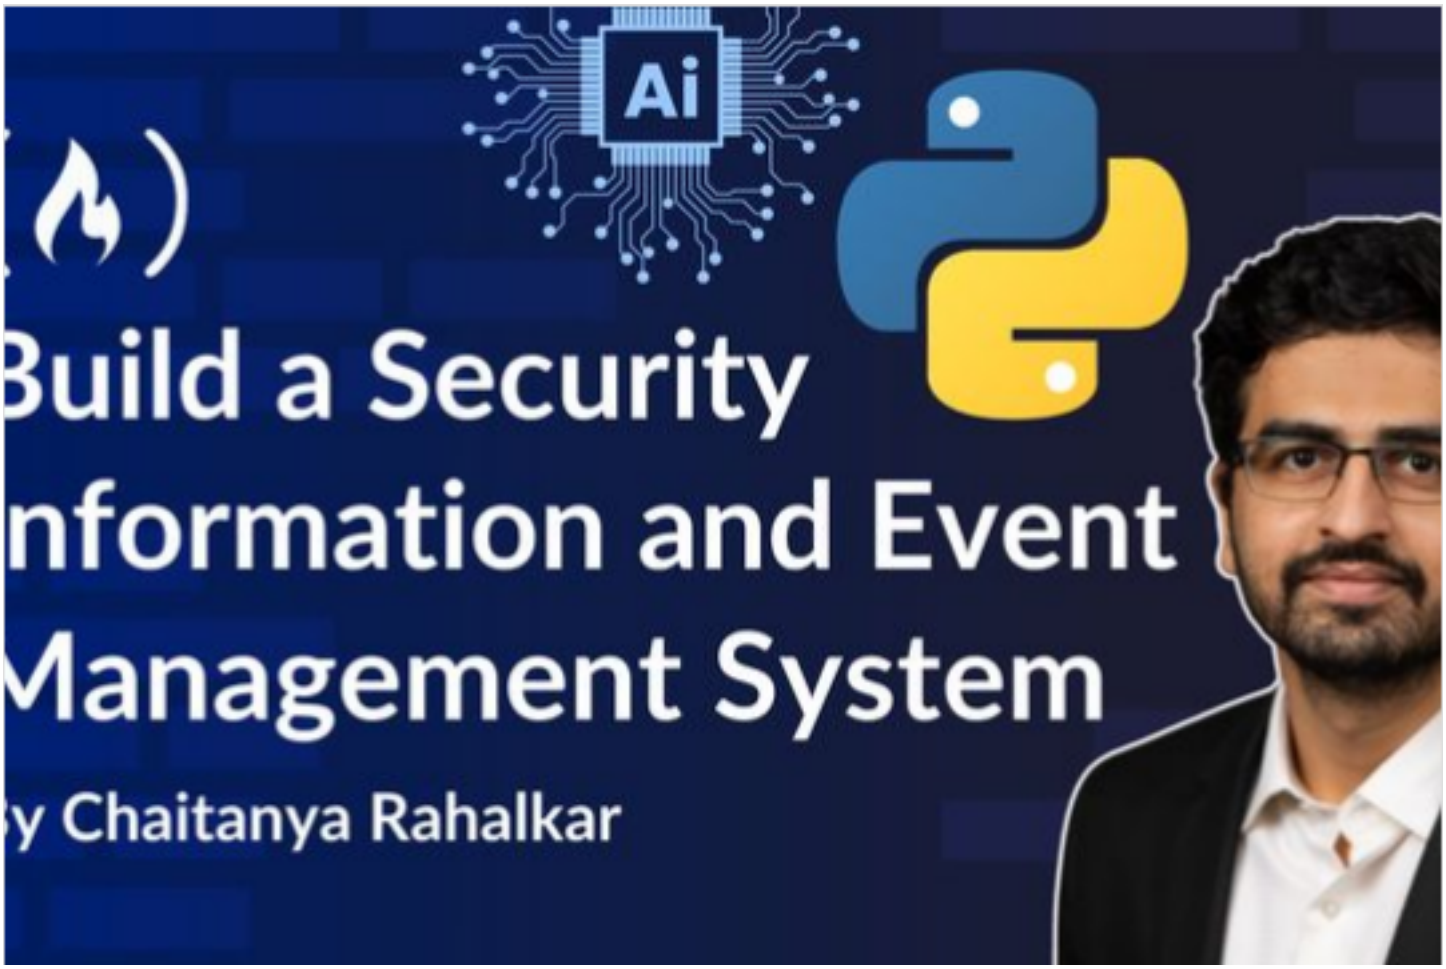

file:///Users/home/Downloads/09-esupdays26-centralisationLogs_detectAnomalies.pdf

Chaque jour les systèmes informatiques génèrent des volumes importants de log. Un log se définit comme étant un fichier texte, compressés ou binaires, de données généré par un ordinateur qui fournit des informations sur les habitudes d'utilisation, les activités ou encore les processus se déroulant au sein d'un système d'exploitation, d'un serveur ou d'autres appareils. Ainsi on peut y retrouver des informations précieuses. Un log est généralement constitué de plusieurs champs, comme par exemple : la

date et l'heure, l'adresse IP, l'identifiant de l'utilisateur, le service ou la ressource accédée, le type de requête effectuée ainsi que l'appareil et le logiciel utilisés pour accéder au service

Le système SIEM (systèmes d'information de sécurité et de gestion des événements) constitue le système nerveux central des opérations de sécurité modernes. Leur but est de regrouper et corréler les événements de l'environnement informatique pour fournir des informations en temps réel sur les incidents potentiels permettant de détecter les menaces et réagir plus rapidement .

En effet une anomalie , aussi connue sous le nom de valeurs aberrantes, sont des événements notamment de données rares ou inattendus qui diffèrent significativement de la majorité des observations. La détection précoce des anomalies est essentielle pour prévenir les violations de données et améliorer la sécurité du réseau. Ainsi la détection d'anomalies, à l'aide d'algorithme par exemple, permet d'identifier ces attaques souvent malveillantes. Il existe différents types d'anomalies :

- les anomalies de points qui représente un événement inhabituel
- les anomalies contextuelles qui représentent une anomalie dans un certain contexte
- les anomalies collectives qui sont un ensemble de données, qui pris ensemble, sont anormales.

Des connexions inhabituelles, un accès géographique suspect, fraude par carte de crédit ou des erreurs de systèmes sont des exemples d'anomalies.

Ainsi l'objectif est la détection de ces anomalies afin de mieux les comprendre et ainsi les prévenir.

Naturellement il est impossible de se pencher manuellement sur chaque log afin d'identifier les anomalies c'est pour cela que l'on utilise le machine learning (ML) qui repose sur des techniques d'apprentissage automatique dans la détection du trafic anormal.

Il existe 2 catégories d'algorithmes : supervisés et non supervisés. L'apprentissage supervisé consiste à utiliser un ensemble de données pour s'entraîner à faire des prédictions et s'ajuster de manière itérative afin de minimiser les erreurs. Cependant cela signifie que nous sommes limités par la disponibilité de données étiquetées de qualité. On y retrouve l'algorithme des k plus proches voisins ou la classification naïve bayésienne. L'apprentissage non supervisé ,est le plus souvent utilisé, consiste à apprendre des modèles de comportement normaux sans avoir besoin d'anomalies étiquetées. On peut aussi retrouver l'apprentissage dit semi-supervisé qui s'entraîne sur des données normales afin de détecter toute déviation. Dans les SIEM modernes on retrouve aussi l'UEBA (User and Entity Behavior Analytics) qui est une approche de cybersécurité qui analyse les comportements des utilisateurs et des entités pour détecter les anomalies telles que des comportements inhabituels. L'UEBA s'alimente de nombreuses sources de logs, le système apprend le comportement habituel de chaque utilisateur et entité sur une période d'observation à partir d'horaires habituels de connexion, de ressources, de localisation ... ainsi chaque nouvel élément sera comparé à la baseline.

Parmi les algorithmes de machine learning les plus utilisés on retrouve :

- Autoencoders (Deep Learning) afin de reconstruire des logs normaux, et s' il arrive à construire un log anormal alors la reconstruction sera fausse lui permettant ainsi de détecter l'erreur.
- PCA (Réduction de dimension) permet de résumer l'information en réduisant le nombre de variables et donc identifier une variance inattendue dans le comportement du système
- K-means (non supervisé) permet de regrouper des données similaires et mettre en évidence les points aberrants et mettre en évidence les anomalies
- Isolation Forest (non supervisé) fonctionne en partionnant aléatoirement les données et en isolant les points. Les anomalies sont les points qui s'isolent rapidement, ce qui le rend idéal pour identifier les valeurs aberrantes dans un ensemble de données sans avoir besoin d'étiquettes.
- DBSCAN (non supervisé) qui identifie les clustering dense et isole les comportements rares.
- Random Forest (supervisé) permet de prédire une valeur ou une catégorie à partir de données existantes.

Les algorithmes non supervisés sont particulièrement adaptés car les logs sont rarement étiquetés.

Afin de détecter de la meilleure des façons on suit certaines étapes.

1- On collecte des logs à partir de différentes sources c'est une étape importante car ce sont ces sources qui conditionneront la détection des anomalies.

2- On effectue le prétraitement. Tout d'abord les données sont nettoyées car lorsqu'elles sont brutes, elles peuvent contenir des aberrations, du bruit ou on peut retrouver des redondances .Ces étapes de nettoyage ont permis de garantir que les données de formation étaient de haute qualité, ce qui est essentiel pour des prédictions précises et fiables. Ensuite celles-ci sont mises sous un certain format. On récupère certaines informations comme l'adresse IP, le nom d'utilisateurs... Puis finalement on transforme ces données textuelles en valeurs numériques afin qu'elles puissent être utilisées par les algorithmes de machine learning.

3- Modélisation. On applique des algorithmes de machine learning comme ceux décrits précédemment sur les données prétraitées pour construire un comportement de profil normal, il s'agit de la baseline.

4- Optimisation des algorithmes. Une fois le modèle entraîné on l'évalue puis on l'affine afin d'améliorer sa précision. Cette étape comprend l'amélioration de la gestion des alertes (détection et alerte en temps réel et réduire effort manuel), la réduction de faux positifs (identification des alertes récurrentes non pertinentes pour affiner les critères de détection), évaluation des performances (F-score, précision) , encore le réglage des paramètres internes de l'algorithme ou même de la sécurité.

5- Détection des anomalies à l'aide d'un seuil basé sur celui de la baseline, si un score dévie de celui-ci alors cela provoque une alerte.

6 - Alerte . Une fois une anomalie détectée, toutes les menaces ne présentent pas le même niveau de danger, il est donc essentiel de les prioriser. On distingue généralement trois niveaux :

- Niveau faible : comportement inhabituel mais non confirmé comme malveillant (connexion depuis un nouvel appareil).
- Niveau modéré : comportement suspect nécessitant une investigation (accès à des ressources inhabituelles à une heure atypique).
- Niveau élevé : menace confirmée ou très probable (exfiltration massive de données).

Selon le niveau de gravité, plusieurs actions peuvent être entreprises : blocage automatique d'une adresse IP, désactivation temporaire d'un compte utilisateur ou notification immédiate de l'équipe de sécurité.

La mise en place d'un système de détection d'anomalies basé sur le machine learning soulève plusieurs défis importants tels que trouver le bon seuil de détection, de bien étiqueter les données , car une erreur impactera le reste, et de réentraîner régulièrement les modèles car le comportement normal d'un utilisateur (baseline) évolue dans le temps.

La détection d'anomalies appliquée aux logs de sécurité est aujourd'hui un élément essentiel de la cybersécurité . Face à l'augmentation du volume et de la complexité des données, les approches basées sur le machine learning, en particulier non supervisé, permettent d'améliorer significativement la détection des menaces inconnues.

Étudier la structure des logs firewall, proxy, syslog et auth.log. Comprendre les champs clés (timestamp, IP source/destination, port, action, utilisateur,

statut). Livrable : tableau comparatif des formats.

SOURCE

🌐 Qu'est-ce que Syslog ? Introduction au protocole de journalisation du sys...

https://docs.redhat.com/fr/documentation/red_hat_enterprise_linux/9/html/deploying_web_servers_and_reverse_proxies/setting-apache-http-server_deploying-web-servers-and-reverse-proxies

https://ieeexplore.ieee.org/abstract/document/9737389

https://www.checkpoint.com/fr/cyber-hub/network-security/what-is-firewall/

- **Severity**: Ce sont des valeurs simples, avec un nombre compris entre 0 et 7 pour identifier le niveau d'importance d'un message
- **Facility** : Type ou origine du log (le "service global") Exemples : auth → authentification , kernel → noyau , mail → emails , daemon → services système

Définitions des champs clés

Timestamp : date et à l'heure exactes auxquelles un événement s'est produit.

IP source : l'adresse IP de l'équipement ou de l'utilisateur à l'origine de la requête ou de la connexion.

IP destination : l'adresse IP de la machine cible vers laquelle la requête est envoyée.
Elle permet de savoir quel système ou service est visé.

Port : numéro associé à un service réseau (ex : 80 pour HTTP, 443 pour HTTPS, 22 pour SSH).
Il permet d'identifier le type de service ou d'application concerné par la communication.

Action : indique la décision prise par le système (souvent un firewall), comme :

- **ALLOW** (autoriser)
- **DENY / DROP (**bloquer**)**
  → Elle permet de savoir si une connexion a été acceptée ou refusée.

Utilisateur : correspond à l'identité de la personne ou du compte ayant effectué une action.
-> Il est essentiel pour analyser le comportement et détecter des accès non autorisés.

Statut: indique le résultat d'une action, par exemple :

- **success** (réussi)
- **failure** (échec)
  → utile pour détecter des anomalies comme des tentatives de connexion répétées.

Les formats de logs en cybersécurité

Les systèmes informatiques génèrent en permanence des **journaux d'événements** (logs) qui tracent tout ce qui se passe sur un réseau ou une machine. En sécurité, l'analyse de ces logs est fondamentale : elle permet de détecter des intrusions, de reconstituer des incidents et de surveiller les comportements anormaux. Il existe quatre grandes familles de logs à connaître.

1. Syslog — le journal système universel

Origine et rôle : Syslog est un protocole standard (défini par la RFC 5424) conçu pour centraliser les journaux d'événements de systèmes d'exploitation (Linux, Windows, macOS) et d'équipements réseau. Son rôle est de notifier l'administrateur sur tout événement significatif : erreur système, redémarrage, modification de configuration, panne.

Nature des données : semi-structurée. Il y a un ordre et des informations identifiables, mais pas de colonnes fixes comme dans une base de données.

Structure complète :

<PRI> HEADER MESSAGE

- **PRI** (Priority) = Facility + Severity. Exemple : <34> = Facility 4 (Auth) × 8 + Severity 2 (Critical)
- **HEADER** = timestamp + hostname. Exemple : Oct 11 22:14:15 server1
- **MESSAGE** = nom du service + description. Exemple : sshd: Failed password for root from 192.168.1.1

Les 8 niveaux de sévérité (du plus critique au moins critique) :

Niveau	Nom	Description
0	Emergency	événements qui désactivent le système.
1	Alert	Action immédiate requise
2	Critical	Conditions critiques
3	Error	Erreur
4	Warning	Avertissement
5	Notice	Condition normale mais significative
6	Informational	Message informatif
7	Debug	Message de débogage

- Niveau 0 : urgence
- Niveau 1 : alerte
- Niveau 2 : conditions critiques
- Niveau 3 : erreur
- Niveau 4 : avertissement
- Niveau 5 : avertissement/notification
- Niveau 6 : informatif
- Niveau 7 : Débogage

Source : RFC 5424 (IETF), PandoraFMS — *Qu'est-ce que Syslog*

2. Logs Firewall (Pare-feu) — le journal du trafic réseau

Rôle : Le pare-feu filtre les communications réseau et enregistre chaque décision prise : autoriser ou bloquer un flux. Ces logs permettent de surveiller le trafic entrant/sortant et de détecter des comportements malveillants (scans de ports, tentatives d'intrusion, exfiltration de données).

Nature des données : structurée (souvent CSV ou champs séparés par des espaces).

Structure (format WELF / Stormshield SNS) :

id=firewall time="2024-03-27 10:15:02" fw="SNS-V50" pri=4

srcif="Ethernet0" src=192.168.1.50 dst=8.8.8.8

proto=tcp sport=54210 dport=443 action=pass

Le **5-tuple** est l'élément central : IP source + Port source + IP destination + Port destination + Protocole. C'est lui qui identifie un flux réseau de manière unique.

Actions possibles :

- PASS / ALLOW : flux autorisé
- BLOCK / DROP : flux bloqué silencieusement
- REJECT : flux bloqué avec notification à l'émetteur

Sources : Documentation Stormshield SNS, CheckPoint Logging Guide

3. Auth.log — le journal d'authentification (Linux)

Rôle : Auth.log est le journal dédié à l'identité sur les systèmes Linux/Debian. Il trace toutes les tentatives de connexion (réussies ou échouées), les élévations de privilèges via sudo, et les sessions ouvertes via SSH ou PAM. C'est l'outil principal pour détecter les attaques par force brute.

Nature des données : semi-structurée (basée sur syslog, donc hérite de sa structure).

Structure :

Mar 27 14:20:10 server1 sshd[1234]: Failed password for invalid user admin

from 203.0.113.5 port 55210 ssh2

- timestamp → Mar 27 14:20:10
- hostname → server1
- service[PID] → sshd[1234]
- statut → Failed password / Accepted password
- utilisateur → admin (ou invalid user)
- IP source + port → 203.0.113.5 port 55210

Statuts clés : Failed password, Accepted password, session opened, session closed, sudo: user NOT in sudoers

Sources : Manual pages Linux (man sshd), Debian Wiki — Authentication Logs

4. Logs Proxy — le journal de navigation web

Rôle : Le proxy est un intermédiaire entre les utilisateurs internes et Internet. Ses logs enregistrent toutes les requêtes web : quelle machine a demandé quel site, à quelle heure, avec quel résultat. Ils permettent de contrôler les accès, filtrer les sites interdits et détecter des comportements suspects (téléchargements anormaux, accès à des domaines malveillants).

Nature des données : semi-structurée (format propriétaire selon le proxy utilisé).

Structure (format Squid) :

1711532400.123 150 192.168.1.50 TCP_MISS/200 4500

GET http://example.com/ user01 DIRECT/93.184.216.34 text/html

Contrairement aux logs firewall qui voient des adresses IP et des ports, le proxy travaille **au niveau applicatif (couche 7)** : il voit les URL complètes, les méthodes HTTP et les utilisateurs authentifiés (souvent via Active Directory).

Codes de cache :

- TCP_HIT : la ressource était déjà en cache (pas de requête vers Internet)
- TCP_MISS : la ressource a dû être récupérée depuis le web

Sources : Squid-cache Wiki, BlueCoat/Symantec ProxySG Documentation

	Syslog	Firewall	Auth.log	Proxy
Rôle principal	Journal général du système journalise tout ce qu'il se passe	Journal de chaque décision de filtrage réseau (autoriser ou bloquer un flux)	Tracer toutes les tentatives d'authentification et les élévations de privilèges	Enregistrer toutes les requêtes web émises par les utilisateurs internes
Équipement source	Tous les systèmes : Linux/unix, Windows, macOS ...	Pare-feu (Stormshield, CheckPoint, Cisco ASA...)	Linux/ Unix	Proxys logiciels ou entreprises(Squid, BlueCoat, Symantec...)
Structure des données	Semi-structurée	Structurée (CSV / champs séparés)	Semi-structurée	Semi-structurée
Champs clés	• Timestamp • Hostname • Service • Message • Severity (gravité) • Facility (origine)	• IP source • IP destination • Port • Action • Statut	• Timestamp • Utilisateur, compte utilisé • IP connexion • Port de connexion • Statut • Service	• Timestamp • IP client • URL • Méthode HTTP • Statut
Élément le plus important	Severity	IP + port	Statut + utilisateur	URL
Exemple de ligne	<34>1 2024-01-15T08:23:01Z	Jan 15 08:23:01 fw01 kernel:	Jan 15 08:23:01 serveur01	1705312981.123 245 192.168.1.10

	serveur01 sshd 1234 - - Accepted password for alice from 10.0.0.5 port 22	IN=eth0 OUT= SRC=192.168.1.10 DST=8.8.8.8 PROTO=TCP SPT=54321 DPT=443 ACCEPT	sshd[1234]: Failed password for bob from 203.0.113.5 port 55123 ssh2	TCP_MISS/2004523 GET https://example.com/ jdupont DIRECT/93.184.216.34
Niveaux / codes propres	• Niveau 0 : urgence • Niveau 1 : alerte • Niveau 2 : conditions critiques • Niveau 3 : erreur • Niveau 4 : avertissement • Niveau 5 : avertissement/notification • Niveau 6 : informatif • Niveau 7 : Débogage	• PASS / ALLOW : flux autorisé • BLOCK / DROP : flux bloqué silencieusement • REJECT : flux bloqué avec notification à l'émetteur	Failed password Accepted password session opened/closed sudo: NOT in sudoers	• TCP_HIT : la ressource était déjà en cache (pas de requête vers Internet) • TCP_MISS : la ressource a dû être récupérée depuis le web
Détection principale	Erreurs système, pannes, redémarrages anormaux et , erreurs applicatives répétées	Connexions vers des ports inhabituels, des IP suspectes, tentatives d'intrusion, exfiltration de données	Détection d’attaques : séries de Failed password depuis une même IP , des connexions en dehors des horaires normaux...	Téléchargements anormaux, tentatives de contournement
Usage principal en	Corrélation d'événements	Contrôle du périmètre	Surveillance des identités	Contrôle d'accès web

sécurité	multi-sources	réseau	et des accès	
Ce que ce log voit	Tout ce que l'OS ou le service décide d' enregistrer dans un fichier log	IP, ports, protocole, action	Identité, méthode d'auth, résultat, IP source	URL complète, méthode HTTP, utilisateur , contenu MIME (le type de ce qui est échangé)
Ce que ce log ne voit pas	Trafic réseau brut, contenu des paquets (texte d'un email, mot de passe écrit ...)	Noms de domaine, URL, identité de l'utilisateur, contenu des paquets	Contenu des sessions, trafic réseau, actions post-connexion	Trafic chiffré non intercepté, protocoles non-HTTP

Trouver des jeux de données publics (CICIDS, UNSW-NB15, logs simulés). récupérer un échantillon anonymisé. Documenter les sources choisies.

Un échantillon anonymisé = un petit extrait de données où les informations personnelles ont été effacées ou remplacées.

On va prendre les data set brutes

1. CICIDS2017 — Version brute complète kaggle.com/datasets/chethuhn/network-intrusion-dataset

2. UNSW-NB15 — Version brute complète (4 fichiers)
kaggle.com/datasets/mrwellsdavid/unsw-nb15

3. Logs simulés bruts — Cybersecurity Threat Detection Logs
kaggle.com/datasets/aryan208/cybersecurity-threat-detection-logs

Nom du dataset	CIC-IDS-2017	UNSW-NB15	Cybersecurity Threat Detection Logs
Date	2017	2015	2024
Créateur	UNB (University of New Brunswick) au sein du Canadian Institute for Cybersecurity (CIC).	Australian Centre for Cyber Security (ACCS) à l'UNSW Canberra.	Aryan208 (Kaggle)
Format	CSV	CSV	CSV
Fichier choisi	Friday-WorkingHours-Afternoon-DDos.pcap_ISCX.csv	UNSW-NB15_1.csv	cybersecurity_threat_detection_logs.csv
Taille	77 Mo	169 Mo	874 Mo
Nombre de lignes	225 745 lignes	700 000 lignes	100 000 lignes
Objectif	Fournir un trafic réseau réaliste et moderne pour tester les systèmes de détection d'intrusion (IDS) et de prévention (IPS)	Remplacer les anciens datasets comme KDD99 qui ne reflétaient plus les attaques modernes. Il mélange du trafic normal avec 9 types d'attaques différentes (Fuzzers, Analysis, Backdoors, DoS, Exploits, Generic, Reconnaissance, Shellcode et Worms).	Entraînement à la détection d'anomalies, il simule la sortie d'un outil de surveillance de type IDS (Système de détection d'intrusion) ou SIEM. Pour permettre de distinguer des activités lambda de comportements suspects grâce à des scores d'anomalie
Contexte	Capture réseau d'un	Premier fichier du	Logs simulés sur

	vendredi après-midi simulant des attaques DDoS , il s’agit d’un type d'attaque où de nombreuses machines inondent un serveur de requêtes jusqu'à le rendre inaccessible	dataset sur quatre, il combine du trafic réseau réel et des attaques simulées générées par l'outil IXIA PerfectStorm qui est utilisé ici pour simuler des attaques de manière réaliste et contrôlée.	toute l'année 2024, imitant les sorties d'un environnement mixte (firewall, IDS, logs applicatifs). Les classes sont volontairement déséquilibrées avec 92% normal, 6% suspect, 2% malveillant pour coller à la réalité d'un réseau d'entreprise
Nombre de features	79	49	10
Exemples de features	• Destination Port : le port ciblé par la connexion • Flow Duration : la durée totale de la connexion en microsecondes • Total Fwd Packets : le nombre total de paquets envoyés dans le sens aller (de la machine source vers la destination) • Total Backward Packets : le nombre total de paquets reçus en retour (de la destination vers la source) • Total Length of Fwd Packets : le volume total en octets de toutes	• srcip : IP source, la machine qui initie la connexion • sport : port source, d'où part la connexion • dstip : IP destination, la machine qui reçoit • dsport : port destination, le service ciblé • proto : protocole utilisé • state : état de la connexion (FIN = terminée 70%, CON = en cours 27%, INT...) • dur : durée de la connexion en secondes • sbytes : volume de données envoyées en octets	• timestamp : la date et l'heure exacte de l'événement • source_ip : adresse IP source, la machine qui initie la connexion • dest_ip : adresse IP destination, la machine qui reçoit la connexion • protocol : le protocole de communication utilisé • action : ce que le système a décidé face à la connexion : allowed ou blocked • threat_label : la classification de la menace :

	les données envoyées dans le sens aller • Total Length of Bwd Packets : le volume total en octets de toutes les données reçues en retour • Fwd Packet Length Max : la taille du plus gros paquet envoyé dans le sens aller • Fwd Packet Length Min : la taille du plus petit paquet envoyé dans le sens aller • Fwd Packet Length Mean : la taille moyenne de tous les paquets envoyés dans le sens aller • Fwd Packet Length Std : l'écart type de la taille des paquets envoyés	• dbytes : volume de données reçues en octets • Sttl : durée de vie du paquet source	benign = normal (92%), suspicious = suspect (6%), malicious = malveillant (2%) • log_type : le type de log qui a généré l'événement : firewall (33%), ids (33%), application (33%) • bytes_transferred : le volume de données transférées en octets • user_agent : le logiciel utilisé pour faire la requête • request_path : le chemin URL accédé car les chemins inhabituels peuvent indiquer une tentative d'intrusion